

意向岗位：AI应用开发工程师

刘力溪 | 群众 | 192-1966-5421 | 3492336010@qq.com



教育背景

- 2023.09-2027.06 毕业院校：**吉首大学(湖南省双一流建设高校，重点一本)
- 专业：**软件工程(国家一流本科专业)
- 曾获奖项：**校级优秀学生奖学金（二等）
- 主修课程：**数据结构与算法、操作系统、计算机网络、数据库原理

个人能力

算法与建模：扎实的数据结构与算法基础，熟悉 STL、复杂度分析及常见算法设计。

具备较强的编码能力和问题拆解能力，能够快速定位并解决复杂技术问题。

Agent 框架：LangChain / LangGraph / AutoGen / Diffy，熟悉状态图机制在复杂 workflows 中的适用场景

RAG 与检索：ChromaDB / Milvus / BM25+向量混合检索（RRF 融合 / BGE-Reranker / 父子分块策略）

大模型基础：熟悉 Transformer 与注意力机制，掌握 LoRA 微调原理与具备面向垂直任务的轻量化模型适配能力

传统后端工程：

- 消息队列：Redis + RQ（异步任务队列）、RabbitMQ
- 数据库：MySQL（事务/索引优化）、Redis（缓存/限流）
- 缓存架构：Redis 双层缓存（本地+分布式）、缓存降级与穿透防护
- 服务与部署：FastAPI / Gin / Docker / Nginx
- 项目架构：多智能体协作编排、RAG 闭环、工具协议集成、多层记忆管理，可独立完成从需求拆解到架构落地的全流程设计

项目经历

项目一：MultiTaskQAAssistant — Multi-Agent 智能客服

时间：2026.03 — 2026.05

技术栈：Python + FastAPI + LangGraph + ChromaDB + Redis + MCP

业务背景与目标

电商平台客服团队面临三大痛点：①大量重复咨询（如订单状态、退换货政策占用人工；②复杂问题需要跨部门（销售/技术/售后）协作，转换效率低；③客服知识库分散，检索准确率不足。目标：构建一个可自动处理80%常见咨询、并能智能分派复杂问题的AI客服系统，降低人工成本的同时提升用户满意度。

我的行动与方案

多智能体协作调度：设计 Supervisor+专用 Agent 的星形架构。Supervisor 通过 LLM 意图识别+规则兜底，将咨询动态分发至销售、技术、售后等专用 Agent，各 Agent 共享上下文状态。基于 DAG 状态图编排并行节点执行，并增加超时熔断与自动 Replan 容错，解决了跨部门协作的效率瓶颈。

三层记忆体系：实现短期对话记忆（Redis）、中期压缩摘要（上下文密度>92%自动触发）、长期用户画像（MySQL + Redis）。跨会话记住用户的偏好商品与历史工单，使多轮对话场景的通过率提升43%，用户无需重复描述问题。

知识库治理与异步处理：针对知识文档批量导入、更新阻塞等问题，引入 Redis + RQ 异步任务队列，支持文档批量导入、增量索引重建和版本回滚；同时搭建后台管理面板（含权限控制与审计日志），让运营人员可自助维护知识库。

Self-RAG + 混合检索：实现 Self-RAG 决策、向量检索 + BM25 混合召回、RRF 融合排序、BGE-Reranker 重排序与 Redis/LocalCache 双层缓存。支持HTML/DOCX/PDF/XLSX/TXT精细结构化分块策略。优化后召回率89.3%，忠实度77.2%，上下文精度81.8%，大幅减少了客服图表不准确而需人工复核的比例。（以上测试基于RAGas知识库生成500个问答对，并人工抽样校验20%样本保证问题合理性）

MCP工具协议与可观测性：集成 MCP 协议暴露查询订单、创建工单等工具，为后续接入外部工具服务器预留扩展；

Agent 评测体系：搭建多维评测体系，支持LLM-as-Judge + RAGAS 端到端评测。支持从知识库文档自动生成测试用例、按类别定向评测、自动生成Md报告。采集各环节延迟，平均响应738ms，P95 2350ms，支持按使用维度的性能分析与告警。

业务结果

- 在模拟环境中验证，500+个由知识文档自动生成的测试问答对（人工抽样20%校验）上，端到端综合通过率达94%，LLM Judge 均分0.96（满分1分），权限泄露率为0。
- 单机压测（4核8G，无GPU）可支撑约 100 QPS，覆盖模拟场景中约65%的常见问题类型。

项目二：智汇金服 · 智能投研助手

时间：2026.03 — 2026.07

技术栈：Python + FastAPI + Redis + Docker + LangChain + Qdrant

业务背景与目标

面向一家中型券商研究所，搭建面向投研人员的智能投研助手，覆盖研报检索、会议纪要解析、舆情监控与问答题库生成。痛点：研究员日均阅读材料超80份，关键信息提取耗时过长；路演会议记录分散，复盘依赖人工整理；合规审查要求溯源引用。目标：实现研报语义检索、会议关键议题提取、自动生成问答对，辅助研究员提升信息处理效率50%以上。

我的行动与方案

- 独立设计“投研大脑”核心流水线：基于RAG实现PDF研报/会议纪要的语义检索与问答，采用Qdrant向量库存储段落Embedding，支持按时间、研究员、行业多维度过滤检索。
- 实现会议录音转写文本的自动纪要生成：结合LangChain + 结构化Prompt工程，抽取“核心结论、争议点、待办事项”三要素，输出Markdown格式纪要，经内部评测可覆盖约75%人工纪要要点。
- 构建“智能问答题库”模块：对存量研报自动生成带答案的QA对（含引用来源），供新人培训及合规自查使用，覆盖500+份历史报告。
- 性能与部署优化：负责Python推理服务的Docker镜像构建与容器化部署，接入公司已有Nginx网关；使用Redis缓存高频检索Query（Top 30问题），将平均检索响应从1.8s压缩至280ms；配合Java团队完成Dubbo接口联调，确保上下游数据一致性。
- 上线后试用期间，日均Query量达200+次，研究员反馈信息检索耗时缩短约40%，会议纪要整理时间由平均3小时/场降至1小时以内。